

Projet Datascientest

Data Product Manager

November 2024

Proposer une amélioration basée sur la data pour Datascientest
avec une solution qui permet d'améliorer les conditions d'apprentissage des apprenants.

Edith Belin, Frédéric Baumgart, Paul Lacroix, Michael Abergel

Discovery

Étape 1 : Analyser le contexte, identifier les besoins

Qui est Datascientest? Quel est son environnement économique, stratégique?

Business Model Canvas		DPM DST NOV 24	Edith/Michael/Paul/Fred	Date:
 Partenaires clés ☐ Entreprises et institutions Allianz, Axa, Bouygues Telecom, BNP Paribas, la Caisse d'Épargne, EDF, Lagardère, Société Générale... ☐ Experts et formateurs 3 000 experts ☐ Plateformes technologiques ☐ Écoles et universités Mines Paris – PSL et Panthéon Sorbonne	 Activités clés ☐ Création et mise à jour du contenu ☐ Marketing et acquisition clients ☐ Gestion de la plateforme ☐ Suivi des étudiants  Ressources clés ☐ Plateforme de formation ☐ Formateurs et experts ☐ Contenu pédagogique ☐ Relations avec entreprises			

Qualitative Discovery

Problématiques rencontrées par les apprenants et valeur de leur résolution

2 méthodes pour collecter les problématiques:

1. Par retour de notre propre **expérience**
2. Par **webscraping** et analyse de sentiments sur les 2 sources d'avis ci-dessous. Les bibliothèques utilisées sont : requests, BeautifulSoup, textblob, pandas et json.

Sources	Avis collectés	Nb d'avis négatifs
www.switchup.org	260	20
www.trustpilot.com	289	5
	549	25

Principaux thèmes relevés :

Service client
Qualité technique de la plateforme
Non-respect des délais annoncés
Faiblesse du contenu pédagogique
Communication,
Manque d'accompagnement personnalisé
Manque de suivi après formation

Principaux points de mécontentements :

Le service client est fréquemment critiqué pour son manque de réactivité, avec des réponses lentes ou inexistantes, parfois après plusieurs semaines. Les délais des formations dépassent souvent ceux annoncés, ce qui crée des désagréments pour les apprenants ayant des contraintes de temps.

La qualité des formations laisse à désirer, avec des formateurs mal préparés ou difficilement compréhensibles, notamment en anglais. L'approche pédagogique est jugée superficielle, se limitant trop souvent à des recherches sur Google ou Stack Overflow plutôt qu'à la transmission de compétences solides. De plus, les estimations du temps nécessaire pour passer les modules sont peu précises, ce qui ajoute à la confusion.


Il y a aussi peu de visibilité sur les modules certifiants du parcours, ce qui empêche les apprenants de savoir précisément à quoi s'attendre. Les modules sont parfois jugés trop difficiles, manquant de découpage ou de structure pour simplifier l'apprentissage.

Le suivi des apprenants est insuffisant, avec des corrections de travaux ignorées et des remarques constructives mal prises en compte, voire sanctionnées par des exclusions des cours. Le rapport qualité/prix est perçu comme médiocre, les frais élevés pour des services qui ne répondent pas aux attentes, ce qui entraîne un sentiment de gaspillage de temps et d'argent chez les participants.

La communication par email est inefficace, avec des informations erronées, notamment sur les horaires des visioconférences, ce qui génère confusion et frustration. Malgré des demandes pour cesser ces envois, cela continue. De plus, les formations manquent de mise en pratique professionnelle et de suivi personnalisé, rendant difficile l'application des compétences dans un cadre réel. Enfin, des problèmes techniques récurrents sur la plateforme d'apprentissage perturbent l'expérience des utilisateurs.

Experience Map persona : nouvel apprenant

Experience Map apprenant

 Objectif	Etape 1	Etape 2	Etape 3	Etape 4
Actions	Inscription	Apprentissage	Echange avec le support	Feedback
Objectifs	Accéder à la formation	Acquérir des compétences	Obtenir des renseignements et de l'aide sur les modules d'apprentissage	Donner son avis pour améliorer la formation
Touchpoints and technologies	Site web Datascientest	Plateforme Datascientest	-Chatbot -email -slack	Collecte via plateforme à la fin de chaque cours et examens pour donner une note et un commentaire
Emotions				
Pain points	problème d'authentification lors de la première connexion.	-Présence de fautes (rédaction et techniques) -estimation du temps annoncé pour faire les modules peu précis -manque de visibilité sur l'éligibilité des certifications -Format des modules distanciels/ manque d'accompagnement et découpage de module selon les niveaux	- Pas de contact téléphonique - Pour les questions complexes, le chatbot n'est pas adapté - Pour les questions urgentes, l'email n'est pas adapté - Pas d'outil pour suivre l'état de sa requête au support	Aucun retour sur les feedback(pas de visibilité sur la prise en compte d'un correctif à apporter)

Analyses quantitatives : Backlog de questions possibles

1. Temps moyen de traitement d'une demande ?

Formule : (Somme des temps de traitement de toutes les demandes) / (Nombre total des demandes traitées)

BDD : table *support*, champs : *etat_support* // champs *timestamp_creation* + table *traitement_demandes*, champ *timestamp_finalisation* = *temps_traitement* de la table *traitement_demandes*

2. Répartition des demandes par apprenant et par formation ?

Formule : (Nombre de demandes par apprenant ou par formation) / (Nombre total des demandes)

BDD : table *apprenants*, champs *id_apprenant*, *choix_formation* + table *support*, champs *id_apprenant*

3. Taux de remplissage du champ commentaire des feedback ?

Formule : (Nombre de feedback avec commentaires) / (Nombre total de feedbacks)

BDD : table *feedbacks*, champs : *id_apprenant*, *note*, *commentaire*, *coquille*

2023	DS	DA	DAE	MLOps	DPM
Nombre de stagiaires inscrits	723	830	261	224	247
Nombre de stagiaires qui ont échoué	105	97	32	65	32
Taux de complétion %	85,5	88,3	87,8	70,8	87

4. Taux d'abandon des formations sur les principaux parcours ?

Formule : (Nombre d'abandons de formation) / (Nombre total d'inscriptions à la formation) x 100

BDD : table *apprenants*, champs *id_apprenant*, *choix_formation* + table *examens*, champs : *id_apprenant*, *note*, *timestamp*, *choix_formation* + table *certifications* champs *id_apprenant*, *timestamp*




5. Taux de reconduction d'une formation ?

Formule : (Nombre d'apprenants ayant reconduit la formation) / (Nombre total d'apprenants ayant suivi la formation initialement) x 100

BDD : table *apprenants*, champs *id_apprenant*, *choix_formation* + table *certifications* champs *id_apprenant*, *timestamp*

Analyse Quantitative:

Schéma base de données



Discovery : Synthèse des problèmes rencontrés | Apprenants

- Les retours des apprenants sont peu ou pas utilisés pour améliorer les cours.

Thème 1 :
Feedback modules

- Le support n'est pas suffisamment réactif et les délais de réponse sont trop longs.

Thème 2 :
Support direct

- Le parcours individualisé de l'apprenant n'est pas intégralement pris en compte

Thème 3 :
Pédagogie

Discovery : Synthèse des problèmes rencontrés | Apprenants

Problème	Description	Impact / Pourquoi résoudre ce problème ?	Solutions de contournement	Valeur de la solution	Améliorations proposées
Qualité des cours insuffisante	Les cours ne sont pas à la hauteur des attentes, avec des coquilles, fautes d'orthographe et des cellules dysfonctionnelles.	Perte de motivation et de temps pour les apprenants. 60% des avis négatifs sur Trustpilot mentionnent la qualité des cours.	Les apprenants tentent de se débrouiller seuls, parfois en cherchant des sources extérieures.	Améliorer la satisfaction des apprenants et augmenter le taux de reconduction des apprenants.	Mettre en place un processus rigoureux de révision des cours et de vérification des supports avant diffusion.
Support pas assez réactif	Temps de réponse trop long, et absence de suivi des demandes des apprenants.	Frustration et déception des apprenants entraînant un taux d'abandon élevé (jusqu'à 30% pour certaines formations).	Les apprenants essaient de contacter d'autres apprenants via le forum, mais cela n'est pas efficace pour des problèmes techniques.	Réduction du taux d'abandon et amélioration de la satisfaction générale.	Mettre en place un système de ticketing pour suivre les demandes et optimiser les délais de réponse.
Calibrage des supports	Les modules sont difficiles à comprendre en raison de leur manque de découpage et de structure.	Manque de clarté entraînant une surcharge cognitive et un apprentissage inefficace.	Les apprenants passent plus de temps à essayer de comprendre sans support suffisant.	Améliorer la rétention d'information et la progression des apprenants.	Simplifier les modules et proposer un découpage plus structuré pour faciliter l'apprentissage.
Absence de feedback exploité	Les retours des apprenants sur les modules ne sont pas intégrés pour améliorer les cours.	Les erreurs ne sont pas corrigées, ce qui crée un sentiment d'inefficacité.	Les apprenants n'ont pas de visibilité sur les actions entreprises suite à leurs retours.	Améliorer la qualité des cours et renforcer l'engagement des apprenants.	Implémenter un système d'analyse et de traitement des feedbacks pour une amélioration continue des modules.

Thème 1 :
Feedback modules

Thème 2 :
Support direct

Thème 3 :
Pédagogie

Discovery : Synthèse des problèmes rencontrés | Apprenants

Problème	Description	Impact / Pourquoi résoudre ce problème ?	Solutions de contournement	Valeur de la solution	Améliorations proposées
Estimation du temps de formation peu précise	Le temps annoncé pour chaque module n'est pas fiable.	Frustration et mauvaise gestion du temps, ce qui peut entraîner un abandon.	Les apprenants ajustent leur emploi du temps au fur et à mesure, mais cela crée un stress.	Diminuer le stress et améliorer l'organisation des apprenants.	Adapter les durées estimées des modules en fonction du niveau des apprenants.
Manque de visibilité sur les modules certifiants	Peu d'informations sont données sur les modules qui mènent à des certifications.	Manque de motivation pour poursuivre les modules certifiants, ce qui impacte l'engagement.	Les apprenants sont incertains sur la valeur des certifications proposées.	Augmenter l'engagement des apprenants dans les modules certifiants et le taux de validation des formations.	Mieux communiquer sur les modules certifiants et les avantages associés.
Difficulté de gestion du temps pour les apprenants	L'organisation du temps entre les modules est complexe à gérer.	Stress supplémentaire lié à l'emploi du temps, ce qui entraîne un taux d'abandon élevé.	Les apprenants essaient de s'adapter à leur emploi du temps sans assistance.	Réduction du stress et augmentation du taux de reconduction.	Offrir un outil de gestion du temps et des alertes pour mieux suivre l'avancée des modules.
Absence d'ancrage mémoriel dans les modules difficiles	Les modules difficiles ne disposent pas de supports facilitant l'ancrage des connaissances.	Les apprenants éprouvent des difficultés à retenir les informations complexes, ce qui nuit à la progression.	Certains essaient de revenir sur les modules plusieurs fois sans méthode d'ancrage spécifique.	Amélioration de la rétention des informations et de la satisfaction des apprenants.	Mettre en place des techniques d'ancrage mémoriel et des révisions progressives pour faciliter la compréhension des modules difficiles.

Thème 1 :
Feedback modules

Thème 2 :
Support direct

Thème 3 :
Pédagogie

Discovery : Excel de priorisation

Nouveau business - Impact sur l'acquisition de nouveaux clients : Peut ouvrir des opportunités de marché ou rendre le produit/service plus attractif pour de nouveaux segments de clientèle.

Croissance du revenu généré via les clients actuel. Développement du portefeuille de client existant / sécurisation des clients existant. Cela peut inclure des améliorations qui augmentent la fidélité des clients, réduisent le taux de désabonnement ou encouragent les clients existants à acheter davantage ou des services additionnels.

Satisfaction : prend en compte l'impact individuel de l'amélioration sur un user en termes de satisfaction et la portée de cette amélioration (combien d'utilisateurs sont impactés par l'amélioration)

Efficience interne - Impact d'une amélioration sur l'efficacité des processus internes de l'entreprise. Elle englobe la capacité à minimiser le gaspillage de ressources tout en maximisant la production et la qualité des services ou produits. En matière d'amélioration de produit, l'augmentation de l'efficience interne pourrait signifier l'automatisation des tâches, l'amélioration des systèmes d'information, la réduction des délais de traitement, l'optimisation des workflows ...

Score 0 : Aucun impact mesurable – L'amélioration n'a pas d'impact sur l'acquisition de nouveaux clients.

Score 1 : Impact faible – L'amélioration pourrait légèrement influencer la décision d'un petit nombre de nouveaux clients potentiels.

Score 2 : Impact modéré – L'amélioration est susceptible d'influencer la décision d'une portion significative de nouveaux clients potentiels et peut légèrement améliorer le taux de conversion.

Score 3 : Impact fort – L'amélioration est un facteur clé dans la décision d'un grand nombre de nouveaux clients potentiels et est prévue pour augmenter substantiellement le taux de conversion.

Score 0 : Pas d'impact – L'amélioration n'a pas d'effet sur le revenu provenant des clients existants et ne contribue pas à la réduction du chum.

Score 1 : Impact léger – L'amélioration peut légèrement augmenter le revenu provenant des clients existants ou atténuer le chum, mais l'effet est marginal.

Score 2 : Impact modéré – L'amélioration mène à une augmentation appréciable du revenu provenant des clients existants ou réduisant ainsi le chum de façon mesurable.

Score 3 : Impact significatif – L'amélioration a un impact majeur sur le revenu généré par le portefeuille de clients existants et diminue

Score 0 : Aucun impact - L'amélioration ne modifie en rien la perception de l'utilisateur et n'affecte pas sa satisfaction.

Score 1 : Impact faible - L'amélioration conduit à une légère augmentation de la satisfaction individuel pour un nombre restreint d'utilisateurs.

Score 2 : Impact modéré - L'amélioration améliore significativement la satisfaction pour un petit groupe d'utilisateurs OU a un impact modéré sur une grande partie des utilisateurs.

Score 3 : Impact important - L'amélioration génère une augmentation substantielle de la satisfaction pour une grande partie des utilisateurs, avec un potentiel de transformation de l'expérience utilisateur dans son ensemble.

Score 0 : Aucun impact – Aucune amélioration n'est observée dans l'efficacité des processus internes de l'entreprise.

Score 1 : Impact faible – L'amélioration entraîne de petites optimisations dans les processus internes qui peuvent légèrement améliorer la performance globale sans changements significatifs.

Score 2 : Impact modéré – L'amélioration conduit à des gains d'efficience notables qui optimisent les processus internes, réduisent les coûts opérationnels ou améliorent la vitesse de réalisation des tâches.

Score 3 : Impact élevé – L'amélioration engendre une transformation majeure de l'efficience interne, avec des gains substantiels en termes de coûts, de temps, et de qualité, affectant positivement plusieurs départements ou l'entreprise dans son ensemble.

Nom de l'amélioration (il s'agit de la formulation fonctionnelle du problème) - on aura une formulation du type "Amélioration de", "Réduction de...", "Augmentation de"	Satisfaction	Nouveau business	Efficience Interne	Croissance du revenu généré via les clients actuel	Score de priorisation
Gestion des feedback	2	1	2	1	6
Refonte du support	2	1	1	1	5
Adaptation des modules	1	0	0	1	2
....					

Veille Technologique | Benchmark : De quelles solutions existantes peut-on s'inspirer pour ces deux problématiques ?

Domaine	Problèmes	Solutions concurrentes	Produits existants	Bibliographies
Feedback et qualité des contenus pédagogiques	Prise en compte des feedbacks (Problème support)	- Khan Academy : Feedback en temps réel, réponses directes des instructeurs. - Duolingo : Feedback instantané avec suggestions d'amélioration, gamification pour l'engagement.	- Grammarly : IA pour feedback en temps réel sur la grammaire et le style. - Socrative : Quiz interactifs avec retours détaillés pour ajuster les leçons.	- <i>"Instant Feedback in E-learning Environments"</i> : Avantages et défis du feedback instantané. - <i>"Role of AI in Personalized Feedback"</i> : Utilisation de l'IA pour personnaliser le feedback.
Qualité des contenus pédagogiques (Problème ressources)	Mise à jour et pertinence des contenus	- Coursera & edX : Collaboration avec des universités pour garantir des contenus à jour et de qualité. - LinkedIn Learning : Mise à jour continue, collaboration avec des experts sectoriels.	- Edmodo : Analyse des performances des étudiants pour améliorer les contenus. - Lumen Learning : Open source pour une amélioration collaborative des ressources pédagogiques.	- <i>"Improving the Quality of Learning Content with AI"</i> : Utilisation de l'IA pour ajuster la difficulté des contenus. - <i>"AI-driven Content Creation for Education"</i> : IA pour la création de contenus personnalisés.
Apprentissage et mémorisation	Renforcement de l'ancrage mémoriel	- Woonoz : Spécialiste de l'ancrage mémoriel, prévoyant des exercices avant de passer à l'étape suivante.	- Systèmes d'apprentissage adaptatif : DreamBox Plateforme d'apprentissage adaptatif qui ajuste le contenu en temps réel en fonction des besoins des étudiants.	- <i>"Studies on the Effectiveness of Memory Anchoring in Digital Education"</i> : Recherche sur l'efficacité des stratégies de mémorisation dans les environnements d'apprentissage numériques.

Veille Technologique | Benchmark :

Autres ressources pour la classification de texte

Titre de l'Article	Résumé	Source
A Survey of Text Classification Algorithms	Cet article présente une vue d'ensemble des méthodes de classification de texte traditionnelles (comme Naive Bayes et SVM) et des approches basées sur des modèles profonds (comme les réseaux neuronaux et l'apprentissage profond).	Singh, S., et al., 2018.
Sentiment Analysis and Opinion Mining	Cet article explore les techniques d'analyse des sentiments et de l'extraction d'opinions, notamment les approches de classification utilisant Naive Bayes, SVM, et des réseaux neuronaux.	Liu, B., 2012.
BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding	L'article introduit BERT, un modèle transformer qui permet une compréhension bidirectionnelle du langage. BERT est particulièrement performant pour les tâches de classification de texte, y compris les feedbacks.	Devlin, J., et al., 2018.
A Comprehensive Review on Text Classification Techniques	Une revue exhaustive des techniques de classification de texte, incluant les approches statistiques traditionnelles, les réseaux neuronaux, et les modèles modernes comme les transformers.	Uysal, R. S., & Gunal, S. G., 2020.
Deep Learning for Sentiment Analysis: A Survey	Cet article analyse l'utilisation des réseaux de neurones profonds pour l'analyse des sentiments, qui peut être étendue à la classification de feedbacks utilisateurs dans diverses applications.	Zhang, Y., et al., 2018.

Conception

Étape 2 : Concevoir

Conception : Modélisation base de données - Explications détaillées.

Remarques générales

- tables *feedbacks* et *logs* font référence à une table *notebooks* manquante
- disparité des types et nommage de la référence à la table *notebooks*
- nombreux autres champs manquant (timestamp de création sur les tables qualitatives => RGPD, localisation pour les utilisateurs internes, état pour les meetings, état pour les feedbacks)
- segmentation des utilisateurs très limitante, en respectant un principe + "ACID" il aurait fallu partir sur une table commune des utilisateurs, répartir les rôles sur une table de relation dédiée, ainsi que toute propriété qui est fonction du rôle. Ceci est une modification majeure et ne sera pas explorée.

Modifications

- table *feedbacks* champ *id_notebook* => à passer en INT pour permettre de s'en servir en FK
- table *logs* champs *notebook* => renommé *notebook_id* et passé en INT pour s'en servir de FK




Ajouts (nouvelles tables)

- Ajout d'une table *notebooks* lien avec les tables *feedback* et *logs* via *id_notebook*
- Ajout d'une table *prediction_feedbacks* lien avec la table *feedbacks* via *id_feedback*

Réorganisation

- colonne la plus à gauche avec les tables "catalog" ou qualitatives, ce sont également les utilisateurs internes et externes
- deux colonnes à droite avec les tables de relation, de "faits"
- simplification visuelle en enlevant les types de données de champs
- code couleur pour les relations (or = apprenants, rouge = correcteurs, violet = animateurs, bleu = support, verts = demandes)

Conception : Schémas des bases de données



Cahier des charges (solution basée sur le ML) : Machine Learning Canvas : Algorithme de Classification des feedbacks utilisateurs

Section	Description
Proposition de Valeur	Automatiser l'analyse et la classification des feedbacks utilisateurs pour améliorer l'expérience clients et optimiser les décisions stratégiques. L'algorithme permettra d'identifier les thèmes récurrents et de prioriser les actions à mettre en place. KPIs : Précision du modèle (>85%), temps de traitement des feedbacks et examens (<1s par requête, <24h si intervention humaine nécessaire), taux d'adoption par les équipes,
Sources de Données	- Feedbacks utilisateurs collectés via l'interface améliorée du backend (structurés). - Données issues des tickets de support (https://learn.datascientest.com/, courriels). - Historique des interactions utilisateurs sur la plateforme. - Open data pour enrichissement sémantique (ex. lexiques de sentiments).
Collecte des Données	- Extraction des messages utilisateurs via API ? ou base SQL. - Labellisation semi-automatique basée sur des modèles de NLP existants (ex. BERT, GPT). - Correction manuelle par des annotateurs humains pour améliorer la qualité des labels. - Filtrage des doublons et des données bruitées (ex. spam, messages trop courts).
Features	- Analyse sémantique : mots-clés, n-grams, embeddings. - Sentiment analysis : score de polarité des messages. - Métadonnées : longueur du message, nombre d'occurrences d'un mot-clé, date/heure. - Profil utilisateur : fréquence des interactions, historique des feedbacks.
Modèles	- Modèle NLP basé sur BERT ou DistilBERT pour la classification des feedbacks. - Modèle supervisé (Random Forest, SVM, XGBoost) en complément pour l'analyse des tendances. - Fine-tuning sur des données spécifiques du projet. - Entraînement sur AWS SageMaker pour optimiser le coût et la scalabilité.
Tâche de ML	Classification de texte : Catégoriser automatiquement les feedbacks en différentes classes (ex. bug, amélioration, fonctionnalité manquante, satisfaction, correction). Détection d'anomalies : Identifier les retours atypiques nécessitant une attention prioritaire. (Ex. si urgent)
Décisions	- Génération de rapports automatiques pour les équipes produit. - Identification des sujets les plus récurrents pour prioriser le développement de nouvelles fonctionnalités. - Envoi automatique d'alertes en cas de feedbacks négatifs fréquents.
Génération de Prédictions	- Prédictions en temps réel lors de la soumission du feedback utilisateur. - API REST pour permettre l'intégration des prédictions dans d'autres outils métier (ex. CRM, dashboards).
Évaluation Offline	- Métriques : Précision, rappel, F1-score sur un dataset de validation. - Comparaison avec des modèles de base (TF-IDF + SVM, LDA pour topic modeling). - Cross-validation pour éviter l'overfitting.
Évaluation et Monitoring	- Suivi de la performance du modèle en production (drift des données, baisse de précision). - Retrain du modèle tous les 3 mois avec de nouveaux feedbacks annotés. - Mise en place d'un tableau de bord de monitoring (AWS CloudWatch, Grafana).

Gestion financière du projet data et planification

Catégorie	Description	Coût Estimé	Période Planning	Détails
Investissement Initial (Coûts uniques) = 10 000 €				
Migration & Mise à jour du Schéma SQL	Refactoring, migration et tests du nouveau schéma	2 000 €	16/03/2025 – 22/03/2025	Travail réalisé par l'équipe administrateur bases de données / Data Engineer
Développement de l'Algorithme de Classification	Conception, développement, entraînement et tests	5 000 €	23/03/2025 – 30/04/2025	Réalisé par l'expert en Machine Learning
Développement & amélioration backend	Ajout d'un module UI/UX pour les feedbacks	3 000 €	23/03/2025 – 30/04/2025	Réalisé par le développeur Web Full Stack
Coûts récurrents mensuels (Infrastructure AWS et maintenance) = 1 500 €				
Stockage AWS de base	Utilisation de services comme S3, RDS	500 €	À partir du 16/03/2025	Estimation pour un volume de données modéré
Stockage AWS supplémentaire (Feedback) ~ 100Go	Stockage additionnel pour données issues des feedbacks	300 €	À partir d'environ 01/05/2025*	Estimation en fonction du volume de feedbacks
Requêtage AWS	Frais liés aux requêtes (lecture, écriture, transferts)	300 €	À partir du 16/03/2025	Basé sur une utilisation moyenne
Opération & Maintenance	Monitoring, sauvegardes, mises à jour et support	400 €	À partir du 16/03/2025	Outils de monitoring et interventions correctives
Coûts récurrents mensuels (Ressources Humaines – durée estimée 3 mois)				
Data Engineer	Mise en place et optimisation des pipelines de données	8 000 €	15/03/2025 – 15/06/2025	Profil expérimenté sur toute la phase initiale
Expert en Machine Learning	Développement et tuning du modèle de classification	9 000 €	23/03/2025 – 15/06/2025	Mobilisé dès le lancement du développement ML
Développeur Web Full Stack	Développement des interfaces, API et intégration backend	8 000 €	23/03/2025 – 15/06/2025	Pour le développement et intégration de l'outil
Synthèse Totale : Coût Global 89 500 € (DEV)				
Mars 2025	Investissement initial Infrastructure AWS Maintenance RH	36 500 €	(15/03/2025 – 14/04/2025)	10 000 € + 1 400 € + 25 000 €
Avril 2025	Infrastructure AWS Maintenance Ressources Humaines	26 500 €	(15/04/2025 – 15/05/2025)	1 400 € + 25 000 €
Mai 2025	Infrastructure AWS Ressources Humaines	26 500 €	(16/05/2025 – 15/06/2025)	1 400 € + 25 000 €
Coûts mensuels (post-projet)	Stockage + requêtes + maintenance	1 500 € / mois	Récurrent	

*Le démarrage du stockage supplémentaire pour les feedbacks peut varier.

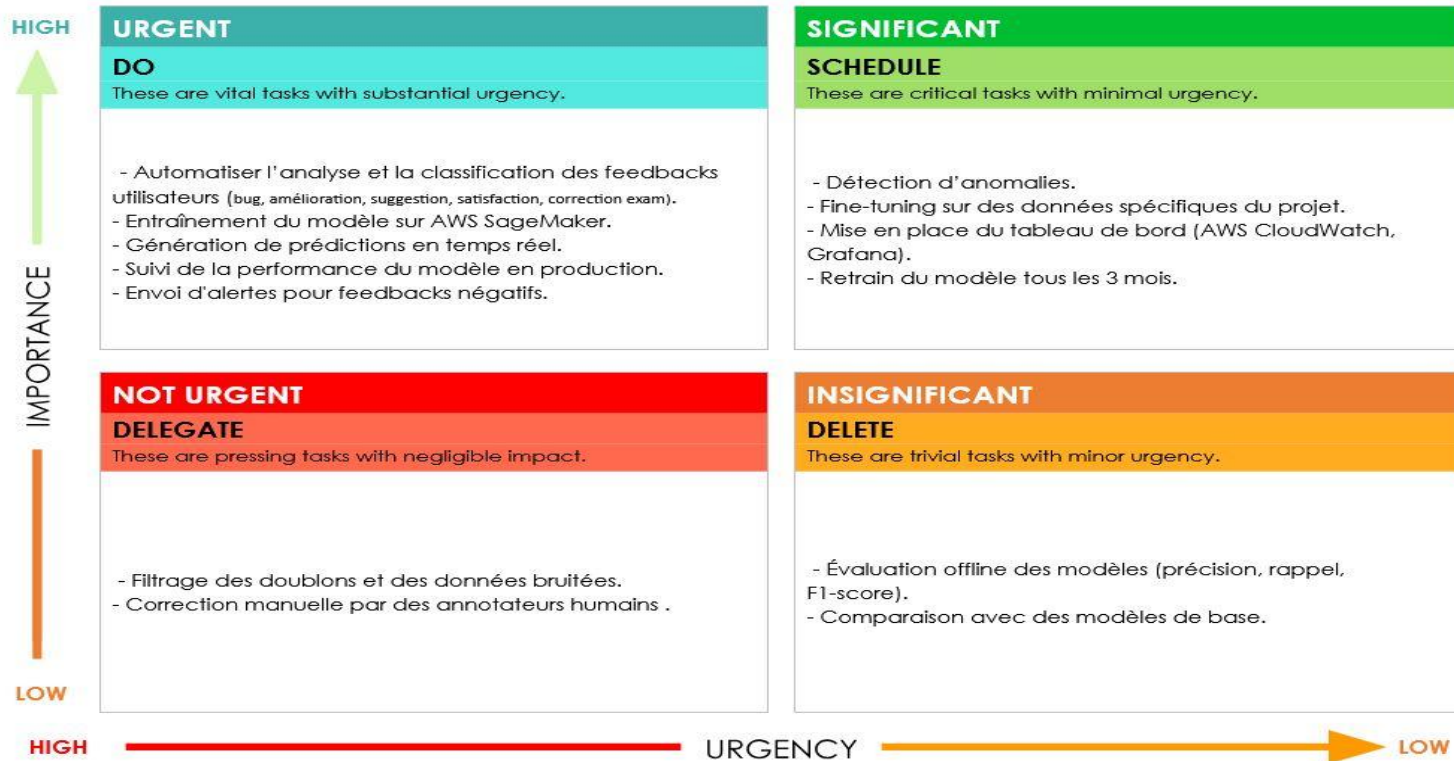
Discovery : Roadmap Produit



Conception : Caractéristiques MVP

MVP	Détails
Esthétique	- Tableau de bord simple avec graphiques (nuages de mots, histogrammes). - Couleurs modernes et discrètes, hiérarchisation claire des informations. - Mode adaptatif pour différentes tailles d'écrans (responsive).
Utilisable	- Interface intuitive, utilisation d'un langage simple. - Accès facile aux fonctionnalités principales (importation des feedbacks, lancement de l'analyse, résultats et priorisation des actions). - Tests rigoureux pour assurer la stabilité (sans bugs).
Faisable	Techniquement : - Modèle de classification NLP pour analyser les feedbacks (ex. BERT, GPT). - Infrastructure cloud scalable pour traitement rapide des données. - Automatisation des actions à suivre. Économiquement : - Lancement d'une solution SaaS avec version de base évolutive. - Priorisation du développement initial autour du cœur du produit (analyse et classement des feedbacks).
Fonctionnel	Fonctionnalités principales : - Importation des feedbacks via API ou fichiers. - Classification des feedbacks (positif, négatif, neutre). - Rapports KPIs (précision du modèle, temps de traitement, adoption utilisateur). - Suggestions d'actions prioritaires. Fonctionnalités supplémentaires : - Module pour les interventions humaines nécessaires. - Suivi et réévaluation continue du modèle basé sur les nouveaux retours.

Conception : Priorisation des fonctionnalités du produit



Conception : Évaluation MVP : disponibilité et qualité des données.

	Cloud AWS
Sources pour adresser la problématique	Champs feedback
Provenance des données	Data Warehouse
Multiplicité des sources de données	Non
Accessibilité des données	Facile
Mise à jour des données	Oui
Les données sont-elles complètes ?	Oui
Les données sont-elles traçables ?	Non
Les données sont-elles sensibles ou personnelles ?	Non
Conformité réglementaire ?	Oui
Quel est le mode d'ingestion des données ?	Flux en temps réel (streaming)
Quelle est la volumétrie des données ?	Petite (100 GB)
Quel est le type de données ?	Structurées
Combien de temps faut-il pour rendre ces données accessibles ?	Immédiat
Les données sont-elles directement accessibles ?	Oui

Développement MVP : tableau de synthèse à destination des DAE et DS

Section	Description
Données d'entrée	Feedbacks utilisateurs (texte), métadonnées (date, ID utilisateur, catégorie existante), historique d'interactions, tickets de support.
Variable à prédire	Catégorie du feedback (bug, amélioration, suggestion, satisfaction, correction exam).
Transformation en sortie	Application d'un argmax pour sélectionner la classe dominante, seuil de confiance pour les cas ambigus (ex si urgent)
Type d'algorithme	Classification supervisée NLP : modèles candidats → BERT / DistilBERT, Random Forest, SVM, XGBoost.
Collecte des données	API de la plateforme, extraction des tickets CRM, annotations humaines pour labellisation.
Labellisation nécessaire ?	Oui, correction manuelle d'un échantillon de données, feedback continu des utilisateurs.
Variables accessibles	Texte du feedback, date et heure, ID utilisateur, historique des interactions, catégorie initiale (si annotée).
Variables complémentaires (Open Data)	Lexiques de sentiment (WordNet, Sentiment140), corpus textuels pour enrichissement (Wikipedia, OpenSubtitles).
Ajout de nouvelles colonnes/tables ?	<u>prediction_categorie</u> , <u>probabilite_prediction</u> , <u>flag_revision_humaine</u> (table feedbacks), <u>date_prediction</u> , <u>version_modele</u> (table de suivi modèle).
Points critiques d'évaluation métier	Faux négatif critique (ex. un problème urgent non détecté), prioriser la détection des feedbacks négatifs.
Métriques ML d'évaluation	Accuracy, Precision, Recall, F1-score, Matrice de confusion, temps d'inférence, monitoring des biais.
Fréquence de prédiction	En temps réel lors de la soumission d'un feedback, stockage des prédictions pour analyse.
Fréquence de ré-entraînement	Tous les 3 mois initialement, puis si la performance chute sous un seuil défini.
Intégration produit/métier	API REST pour requêtage backend, tableau de bord des tendances des feedbacks, alerte automatique en cas de feedback critique.

Lancement

Étape 3 : Concevoir

Lancement du produit :

- Mise à disposition de l'application à une équipe test
- Coordination du plan de communication (Marketing, Équipes pédagogiques, Apprenants Kick-Off)
- Communication sur les dates de mise en place du lancement
- Organiser les migrations en fonction des retours tests.

Questions

Merci

ANNEXES

ANALYSE SWOT : *Éléments qui peuvent influencer la stratégie de Datascientest (2025 - 2027)*

FORCES	FAIBLESSES
• Formation en ligne flexible et adaptée aux professionnels. • Accréditations et certifications reconnues. • Collaboration avec des entreprises partenaires pour l'insertion professionnelle. • Approche axée sur des projets concrets, ce qui favorise l'apprentissage pratique. • Offre encore limitée à certains types de métiers de la data.	• Manque de diversité géographique dans l'offre, avec une concentration en France. • Difficulté à maintenir un suivi personnalisé pour un grand nombre d'étudiants. • Éventuelle standardisation du contenu de formation, peu d'adaptabilité à des besoins très spécifiques.
MENACES	OPPORTUNITES
• Évolution rapide du secteur, rendant nécessaire une mise à jour continue du contenu. • Concurrence accrue avec d'autres écoles et plateformes de formation, dont celles spécialisées dans l'IA. • Pénurie de talents dans la data science qui rend difficile la fidélisation des étudiants. • Risque d'un manque de diversité dans le recrutement des étudiants, limitant l'innovation et l'inclusivité. • Problèmes liés à l'adaptation du modèle pédagogique à un nombre croissant d'étudiants. • Vulnérabilité face aux évolutions du marché du travail, notamment les changements dans les outils et technologies de data science.	• Croissance du marché de la data science à l'échelle mondiale. • Accroître les partenariats internationaux et la visibilité à l'échelle mondiale. • Développement de formations continues pour les professionnels en activité. • Multiplication des offres en ligne et hybrides pour attirer de nouveaux profils. • Collaboration renforcée avec des leaders technologiques pour des certifications reconnues. • Offrir davantage de bourses et de financements pour rendre les formations plus accessibles.

Conception : Questionnaire à destination des clients internes (Amélioration de l'expérience apprenant)

Bonjour,

Dans le cadre de l'amélioration continue de nos formations et de notre accompagnement, nous recueillons vos retours. Votre contribution est essentielle pour identifier les points d'amélioration et garantir une meilleure satisfaction des apprenants.

Merci de prendre quelques minutes pour répondre à ce questionnaire.

1. Informations générales

1.1. Quel est votre rôle au sein de Datascientest ?

☐ Formateur ☐ Correcteur ☐ Staff Support

1.2. Depuis combien de temps travaillez-vous chez Datascientest ?

☐ Moins de 6 mois ☐ 6 mois - 1 an ☐ 1 - 3 ans ☐ Plus de 3 ans

2. Réactivité et accompagnement des apprenants (*Problème 1*)

2.1. Pensez-vous que le service client et le support aux apprenants sont réactifs et efficaces ?

☐ Oui ☐ Non ☐ Moyennement

Pourquoi ?

(Question ouverte)

2.2. Avez-vous déjà reçu des retours d'apprenants concernant des réponses tardives ou inexistantes du support ?

☐ Oui, fréquemment ☐ Oui, occasionnellement ☐ Non, jamais

Si oui, pouvez-vous donner des exemples ?

(Question ouverte)

2.3. Selon vous, comment pouvons-nous améliorer la réactivité du service client et du support pédagogique ?

(Question ouverte)

2.4. Le suivi des apprenants est-il suffisant en termes de corrections, feedbacks et accompagnement ?

☐ Oui ☐ Non ☐ Moyennement

Pourquoi ?

(Question ouverte)

2.5. Avez-vous constaté des erreurs ou des confusions dans la communication par email (horaires erronés, informations contradictoires, etc.) ?

☐ Oui, souvent ☐ Oui, parfois ☐ Non, jamais

Si oui, quels types d'erreurs avez-vous observés ? *(Question ouverte)*

2.6. Quels types de problèmes techniques sont les plus fréquents sur la plateforme d'apprentissage ?

(Question ouverte)

Conception : Questionnaire à destination des clients internes (Amélioration de l'expérience apprenant)

3. Qualité des formations et respect des délais (Problème 2)

3.1. Les délais annoncés pour les formations sont-ils respectés ?

☐ Oui, toujours ☐ La plupart du temps ☐ Rarement ☐ Non, jamais

Pourquoi ?

(Question ouverte)

3.2. Quels sont, selon vous, les principaux obstacles au respect des délais ?

(Question ouverte)

3.3. La qualité des interventions des formateurs est-elle satisfaisante ?

☐ Oui ☐ Non ☐ Moyennement

Pourquoi ?

(Question ouverte)

3.4. Avez-vous des suggestions pour améliorer la préparation et la clarté des formateurs ? *(Question ouverte)*

3.5. Les contenus pédagogiques sont-ils suffisamment approfondis et bien structurés ?

☐ Oui ☐ Non ☐ Moyennement

Pourquoi ?

(Question ouverte)

3.6. Les estimations de temps pour passer les modules sont-elles réalistes ?

☐ Oui ☐ Non, elles sont sous-estimées ☐ Non, elles sont surestimées

Si non, comment les ajuster selon vous ?

(Question ouverte)

3.7. Pensez-vous que les formations offrent assez de mise en pratique et de préparation à un contexte professionnel réel ?

☐ Oui, largement ☐ Moyennement ☐ Non, cela manque

Quels types d'exercices ou projets pratiques devraient être ajoutés ?

(Question ouverte)

3.8. Quels changements proposeriez-vous pour améliorer l'expérience d'apprentissage ? *(Question ouverte)*

4. Suggestions finales

4.1. Si vous pouviez améliorer un seul aspect des formations ou du support aux apprenants, lequel serait-il ?

(Question ouverte)

4.2. Souhaitez-vous être contacté(e) pour discuter plus en détail de vos réponses ?

☐ Oui ☐ Non

Merci pour votre participation !

Vos retours nous aideront à apporter des améliorations concrètes et à offrir une meilleure expérience aux apprenants.

Développement MVP : prototype frontend

What did you think of this exercise?



Feel free to share your feedback

Cancel

Submit

What did you think of this exercise?
(Que pensez-vous de ce module ?)



Feel free to share your feedback
(Sélectionner le menu ci-dessous en cas de commentaires)

Bug technique
Correction de Texte
Suggestion pédagogique
Ma satisfaction
Correction examen

Cancel

Submit

KPI

Nb demandes
30K

